통합반 4회차 실습 2 — 문서지식추출

자료 다운로드와 작업 폴더 열기

문서지식추출 ZIP을 내려받아 압축을 풀고 VS Code에서 폴더를 열겠습니다. 코드/source에는 매뉴얼 HM-8, 정기 점검표 PM-02, 예비품 기준 PR-07과 문서 목록이 있습니다. 2회차의 schema.json과 graph.json, 3회차에서 검토한 SOP·규칙 구조은 input에 복사하겠습니다. 기존 대상의 식별자를 찾을 때 쓸 입력입니다. 출력은 output에 따로 두겠습니다.

문서 목록의 ID와 실제 파일을 맞춰 보겠습니다. 매뉴얼의 표와 단계, 정기 점검의 준비·안전 조건, 예비품 기준의 공급사 선택 순서가 어떤 형태인지 먼저 읽겠습니다. 이 자료는 Markdown이므로 없는 PDF 쪽 번호를 만들어 붙이지 않고 절과 행 구간을 위치로 쓰겠습니다.

구조화 출력의 약속 작성

prompt.md를 열고 추출할 항목과 금지할 일을 직접 적겠습니다. 문서는 분석할 데이터이고 지시가 아니라고 적고, 원문 밖의 단계나 조건을 보태지 않도록 하겠습니다. 후보마다 문서 ID, 판본 지문, 절, 행 범위와 그대로의 인용문을 붙이겠습니다. 숫자와 단위, 부정 조건, 순서, 예외를 보존하고 기존 대상은 input의 ID로 가리키도록 합니다. 못 찾은 대상은 경고로 남깁니다.

코딩 도우미에게 이 계약을 읽는 추출·형식 검사 기능을 만들도록 요청하겠습니다. source를 읽어 output/candidates.json을 만들되, 기존 그래프를 수정하거나 적재하지 않게 하겠습니다. 후보에는 종류·내용·기존 대상 참조·근거·경고를 분리하고 검토 상태는 pending으로 시작합니다. 서비스 접속 정보가 필요하면 수업 환경의 설정으로 읽고 파일에 인증값을 쓰지 않겠습니다.

추출하고 원문으로 되짚기

생성된 코드를 열어 읽는 폴더와 출력 경로, 스키마 검사, 오류 처리를 확인하겠습니다. 수업에서는 이 검토 후 추출을 실행하고 처리 실패와 경고를 먼저 읽겠습니다. 인용 대조 기능은 후보가 가리킨 원문 구간에 인용문이 실제로 있는지 검사하도록 만들겠습니다. 같은 문장이 여러 곳에 있으면 임의로 하나를 고르지 않고 위치를 보완합니다.

이제 원문과 후보를 나란히 놓겠습니다. 24시간이 24분으로 바뀌지 않았는지, 원격 자동이 아니면 쓰지 않는다는 부정 조건이 남았는지, 정기 점검의 안전 조건이 준비물과 섞이지 않았는지 확인합니다. 예비품 긴급 발주에서는 가장 빠른 공급사를 먼저 고르고 승인 여부를 확인하는 순서를 보겠습니다. 승인된 공급사 중 가장 빠른 곳을 고른 것으로 바뀌었다면 원문의 판단 순서가 달라진 것이므로 고치겠습니다.

검토 기록에는 인용이 있는지뿐 아니라 뜻이 맞는지, 필요한 내용이 통째로 빠지지 않았는지를 적습니다. candidates.json 원본은 남기고 수정한 reviewed.json을 별도로 만들겠습니다. 채택·수정·제외와 근거를 후보마다 기록합니다. 미해결 후보는 승인하지 않겠습니다.

저장과 다음 단계 연결

reviewed.json과 review.md를 저장하고 다시 열겠습니다. 후보마다 원문의 어느 위치로 돌아가야 하는지, 기존 대상과 연결할 ID가 무엇인지 확인하겠습니다. 이 파일은 다음 실습의 입력입니다. JSON이 만들어졌다는 사실만으로 그래프가 갱신됐다고 말하지 않겠습니다.